

Portfolio

Elektromobilität in den USA Entwicklungen und Unterschiede

WWI23B4 - Introduction to Data Science

Kelmendi, Salih
Kavak, Arzum
Schulz-Schrade, Jan

4. Dezember 2023

Inhaltsverzeichnis

1	Einleitung	1
2	Business Understanding	1
3	Data Understanding	1
4	Data Preperation	2
4.1	Verwendete Python Bibliotheken	2
4.2	Datensatz 1 - Vehicle Registrations	2
4.3	Datensatz 2 - Alternative Fuel Stations	3
4.4	Datensatz 3 - USA	3
5	Modelling	3
5.1	Anteil der E-Autos am Fahrzeugmarkt	3
5.2	Anzahl Elektrofahrzeuge je Bundesstaat	4
5.3	Geografische Verteilung der Ladesäulen	5
5.4	Anzahl der Ladesäulen je Bundestaat	6
5.5	Zeitliche Entwicklung der Anzahl der Ladesäulen + Trend	7
5.6	Korrelation zw. Anzahl der Ladesäulen und anderen Faktoren	8
5.7	Korrelation zw. Anzahl der E-Autos und politischer Einstellung	9
6	Evaluation	10

1 Einleitung

Die Mobilität ist im Wandel – Seien es die neuen und vielversprechenden Ambitionen aus Paris, die die Metropole zur Fahrradstadt sprießen lassen, oder die großen Entwicklungen des Automobilherstellers Tesla in der E-Mobilität. Heutzutage ist es gang und gäbe, dass Regierungen auf der ganzen Welt fossilen Energien den Rücken zukehren und nach Lösungen suchen, ihren Verkehr emissionsärmer und effizienter umzusetzen. Dabei sind Die Vereinigten Staaten keine Ausnahme: Die E-Mobilität nahm in den letzten Jahren immer weiter an Fahrt auf und nimmt immer mehr Anteil am täglichen Verkehrsgeschehen. Doch wie verläuft diese Entwicklung in einem der kulturell, politisch und sozial heterogensten Länder der Welt? Wie sieht es mit den regionalen Unterschieden aus? In diesem Portfolio werden diese und viele weitere Fragen erforscht und beantwortet.

2 Business Understanding

In unserem Projekt haben wir uns am CRISP-DM-Prozess orientiert, um effiziente und strukturierte Arbeitsabläufe zu gewährleisten. Wir wollen die verschiedenen US-Bundestaaten auf die Entwicklung der E-Mobilität untersuchen. Unsere Leifragen sind:

- Welche Staaten haben am meisten bzw. am wenigsten E-Autos?
- Gibt es regionale Gemeinsamkeiten bzw. Unterschiede?
- Welche Staaten haben die beste Infrastruktur für E-Mobilität?
- Gibt es eine Korrelation zwischen der Infrastruktur und der Anzahl von E-Autos?
- Gibt es eine Korrelation zwischen der E-Mobilität und der politischen Einstellung?

3 Data Understanding

Um die Entwicklung und die regionalen Unterschiede der E-Mobilität in den USA näher beleuchten zu können, benötigen wir Datensätze bezüglich der Infrastruktur und der Beliebtheit des Elektroautos in den einzelnen Bundesstaaten. Deshalb nutzen wir drei Datensätze, die genau diese Informationen preisgeben: Unser erster Datensatz enthält alle registrierten Fahrzeuge im Zeitraum 2016 bis 2022 nach Antriebstechnologie und Bundesstaat unterteilt und enthält 357 Zeilen. Hierbei wird auf die nächsten hundert Fahrzeuge gerundet. Um Anhaltspunkte für die Entwicklung der Infrastruktur zu erhalten, nutzen wir ein regelmäßig aktualisierten sowie äußerst umfangreichen sechzigtausendzeiligen Datensatz mit allen vorhandenen und geplanten E-Ladesäulen in den USA, mit Informationen von der Eröffnung der Ladesäule bis hin zu der genauen Position. Die beiden Datensätze stammen von dem US Department of Energy.¹ Darüber hinaus nutzen wir ein eigens zusammengestelltes kleines Dataset, in dem die politischen und geographischen Eckdaten der Bundesstaaten erfasst werden. Die Daten haben wir aus dem Zensus und den letzten Präsidentschaftswahlergebnissen erhoben. Wir haben bei der Auswahl auf die Reputation unserer Quellen besonders geachtet. Sie stammen direkt von der Website des US Energieministeriums oder einer anderen staatlichen Quelle wie einer Zensuserhebung, daher können wir von einer hohen Genauigkeit ausgehen.

¹US Department of Energy - Alternative Fuels Data Center

4 Data Preperation

In der Phase der Datenbereinigung werden umfangreiche Maßnahmen ergriffen, um Störungen und Inkonsistenzen in den uns vorliegenden Daten zu beseitigen. Dieser Prozess sichert die Qualität und Verlässlichkeit der analysierten Informationen, indem unpräzise oder nicht standardisierte Daten bearbeitet werden. Durch Umbenennen, Aggregieren und Bearbeiten der Datensätze wird eine solide Grundlage für weiterführende Analysen und Modelle geschaffen, die fundierte Einblicke in die Entwicklung der Elektromobilität in den USA ermöglichen.

4.1 Verwendete Python Bibliotheken

```
import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
import folium

from sklearn.linear_model import LinearRegression
from sklearn.model_selection import train_test_split
from sklearn.metrics import r2_score
from sklearn.metrics import mean_squared_error
from folium.plugins import HeatMap
```

4.2 Datensatz 1 - Vehicle Registrations

Wir haben die Fahrzeugregistrierungsdaten bearbeitet und die Spalte 'Electric (EV)' in 'Electric' umbenannt, Tausendertrennzeichen in numerischen Spalten entfernt und diese in int-Datentypen konvertiert. Zudem haben wir die Hybridfahrzeuge zur Spalte 'Hybrid', Diesel- und Benzinfahrzeuge zu 'Fuel' und alle anderen und unbekannten zu 'Other' aggregiert, indem wir Summen für jede Kategorie erstellt haben.

```
# dataset 1 - vehicle registrations
registrations = pd.read_csv('data/vehicle_registrations.csv')

registrations.rename(columns={'Electric (EV)': 'Electric'}, inplace=True)

for column_name, values in registrations.items():
    if column_name != 'State':
        registrations[column_name] = registrations[column_name].replace({' ': ''}, regex=True).astype(int)

columns_to_remove = ['Plug-In Hybrid Electric (PHEV)', 'Hybrid Electric (HEV)']
registrations['Hybrid'] = registrations[columns_to_remove].sum(axis=1)
registrations.drop(columns=columns_to_remove, inplace=True)

columns_to_remove = ['Gasoline', 'Diesel']
registrations['Fuel'] = registrations[columns_to_remove].sum(axis=1)
registrations.drop(columns=columns_to_remove, inplace=True)

columns_to_remove = ['Biodiesel', 'Ethanol/Flex (E85)', 'Compressed Natural Gas (CNG)', 'Propane',
↳ 'Hydrogen', 'Methanol', 'Unknown Fuel']
registrations['Other'] = registrations[columns_to_remove].sum(axis=1)
registrations.drop(columns=columns_to_remove, inplace=True)
```

4.3 Datensatz 2 - Alternative Fuel Stations

Folgend haben wir die für die weitere Analyse relevanten Spalten ('State', 'Latitude', 'Longitude', 'Open Date') aus dem Datensatz zu alternativen Kraftstofftankstellen extrahiert. Zudem haben wir die 'Open Date'-Spalte in ein Datumsformat konvertiert, um uns zeitliche Analysen der Elektromobilitätsinfrastruktur in den USA zu ermöglichen.

```
# dataset 2 - alternative fuel stations
columns_to_keep = ['State', 'Latitude', 'Longitude', 'Open Date']

stations = pd.read_csv('data/alt_fuel_stations (Dec 2 2023).csv', usecols=columns_to_keep, engine='python')

stations['Open Date'] = pd.to_datetime(stations['Open Date'], format='%Y-%m-%d')
```

4.4 Datensatz 3 - USA

An dieser Stelle lesen wir den Datensatz 'usa.csv' ein und passen die Spalten 'Population' und 'Land_area' an, indem wir Tausendertrennzeichen entfernen und die resultierenden Zeichenketten in numerische Werte umwandeln.

```
# dataset 3 - USA
usa = pd.read_csv('data/usa.csv')

columns_to_int = ['Population', 'Land_area']
usa[columns_to_int] = usa[columns_to_int].replace({' ',''}, regex=True).apply(pd.to_numeric)
```

5 Modelling

Im Folgenden haben wir unsere Daten analysiert und grafisch dargestellt, um Antworten auf unsere Fragestellungen zu erhalten.

5.1 Anteil der E-Autos am Fahrzeugmarkt

```
# Vergleich Anteil 2016 zu 2022
registrations_type16 = registrations[registrations['Year'] == 2016]
registrations_type16 = registrations_type16.drop(columns={'Year', 'State'})
registrations_type16 = registrations_type16.sum()

registrations_type22 = registrations[registrations['Year'] == 2022]
registrations_type22 = registrations_type22.drop(columns={'Year', 'State'})
registrations_type22 = registrations_type22.sum()

legend16 = [f'{label} ({value/registrations_type16.sum()*100:.2f}%)' for label, value in
↳ zip(registrations_type16.index, registrations_type16)]
legend22 = [f'{label} ({value/registrations_type22.sum()*100:.2f}%)' for label, value in
↳ zip(registrations_type22.index, registrations_type22)]

fig, axs = plt.subplots(1, 2, figsize=(10, 5))

axs[0].pie(registrations_type16, startangle=90)
axs[0].set_title('2016')
axs[0].set_xticks(axs[0].get_xticks())
axs[0].set_xticklabels(axs[0].get_xticklabels(), rotation=90, fontsize=8)
axs[0].legend(legend16, loc="center left")


axs[1].pie(registrations_type22, startangle=90)
axs[1].set_title('2022')
```

```

axs[1].set_xticks(axs[1].get_xticks())
axs[1].set_xticklabels(axs[1].get_xticklabels(), rotation=90, fontsize=8)
axs[1].legend(legend22, loc="center right")

plt.tight_layout()
plt.show()

```



Um eine vergleichende Grafik zu erstellen, haben wir jeweils die Fahrzeugzahlen aus den Jahren 2016 und 2022 summiert. Die mit den Variablen erstellten Legenden (legend16 und legend22) enthalten prozentuale Anteile der einzelnen Fahrzeugtypen im Jahr 2016 bzw. 2022 im Verhältnis zur Gesamtanzahl der Fahrzeuge in diesen Jahren. Folgend haben wir zwei Kreisdiagramme für die jeweiligen Jahre erstellt. Das Diagramm ermöglicht einen visuellen Vergleich der Veränderungen im Anteil verschiedener Fahrzeugtypen von 2016 zu 2022 und zeigt, dass sich der Anteil der Elektrofahrzeuge in diesem Zeitraum zwar um etwa das 8-fache erhöht hat, jedoch noch nicht 1% der registrierten Fahrzeuge ausmacht.

5.2 Anzahl Elektrofahrzeuge je Bundesstaat

```

# Anzahl Elektrofahrzeuge je Bundesstaat
reg_per_state = registrations[registrations['Year'] == 2022]
reg_per_state = pd.merge(reg_per_state, usa, on='State')


fig, axs = plt.subplots(1, 2, figsize=(13, 5))

axs[0].bar(reg_per_state['Abbreviation'], reg_per_state['Electric'])
axs[0].bar(reg_per_state['Abbreviation'][4], reg_per_state['Electric'][4], color='cyan')
axs[0].bar(reg_per_state['Abbreviation'][11], reg_per_state['Electric'][11], color='magenta')
axs[0].bar(reg_per_state['Abbreviation'][47], reg_per_state['Electric'][47], color='orange')
axs[0].set_title('Anzahl an registrierter E-Autos (2022)')
axs[0].set_xticks(axs[0].get_xticks())
axs[0].set_xticklabels(axs[0].get_xticklabels(), rotation=90, fontsize=8)

reg_pop = reg_per_state['Electric'] / reg_per_state['Population']
axs[1].bar(reg_per_state['Abbreviation'], reg_pop)
axs[1].bar(reg_per_state['Abbreviation'][4], reg_pop[4], color='cyan')
axs[1].bar(reg_per_state['Abbreviation'][11], reg_pop[11], color='magenta')
axs[1].bar(reg_per_state['Abbreviation'][47], reg_pop[47], color='orange')
axs[1].set_title('Anzahl an registrierter E-Autos (2022) / Einwohner')
axs[1].set_xticks(axs[1].get_xticks())
axs[1].set_xticklabels(axs[1].get_xticklabels(), rotation=90, fontsize=8)

plt.tight_layout()
plt.show()

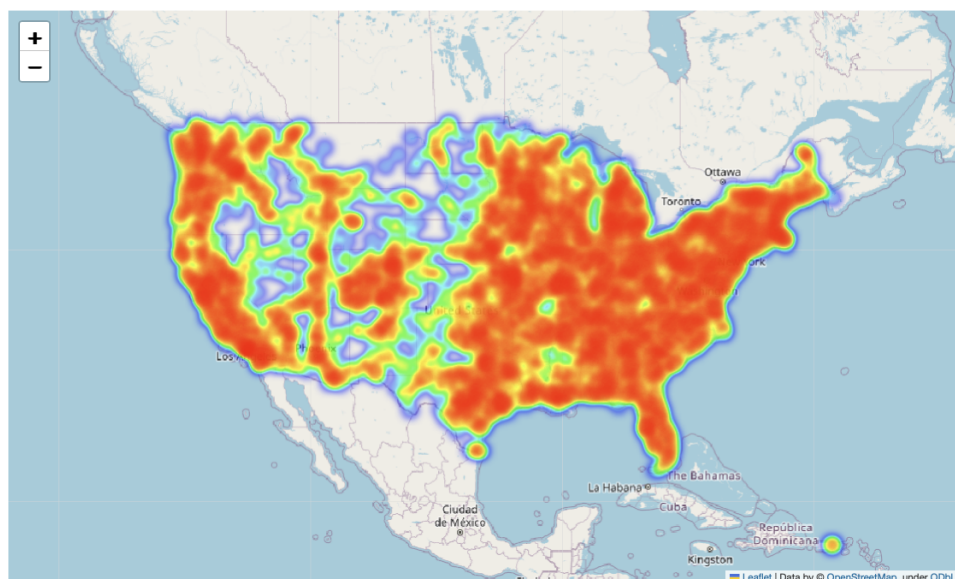
```



Das erste Diagramm zeigt die absolute Anzahl der registrierten Elektrofahrzeuge im Jahr 2022 pro Bundesstaat (mit Abkürzung), während das zweite Diagramm die Anzahl der Elektrofahrzeuge pro Einwohner darstellt. Hier fällt stark auf, dass der Bundesstaat Kalifornien bei den absoluten Werten andere Bundesstaaten dominiert und auch bei der relativen Statistik weit vorne liegt. Hier holen jedoch Bundesstaaten wie Hawaii, Washington, Oregon, Nevada und New Jersey stark auf. Hingegen sind die Staaten Florida und Texas, die nach absoluten Zahlen höhere Werte aufweisen, beim relativen Vergleich eher im Mittelfeld. Kaum eine Präsenz in keiner von beiden Tabellen zeigen die Staaten Mississippi, North und South Dakota, West Virginia und Wyoming.

5.3 Geografische Verteilung der Ladesäulen

```
# Wie sind die Ladesäulen in den USA geografisch verteilt
map_center = [stations['Latitude'].mean(), stations['Longitude'].mean()]
my_map = folium.Map(location=map_center, zoom_start=5)
heat_data = [[row['Latitude'], row['Longitude']] for index, row in stations.iterrows()]
HeatMap(heat_data, radius=10, blur=7).add_to(my_map)
my_map
```



Die folgende Visualisierung zeigt die geografische Verteilung von Ladestationen in den USA. Zunächst wird der geografische Mittelpunkt der Ladestationen berechnet und als Zentrum für die Karte festgelegt. Mit Folium wird eine Karte erstellt. Die Heatmap verdeutlicht, dass der gesamte Osten und Teile des Westens der USA eine gute Ladesäuleninfrastruktur haben, während besonders der Norden und die Mitte der USA große Lücken in ihrem Ladesäulennetz aufweisen.

5.4 Anzahl der Ladesäulen je Bundesstaat

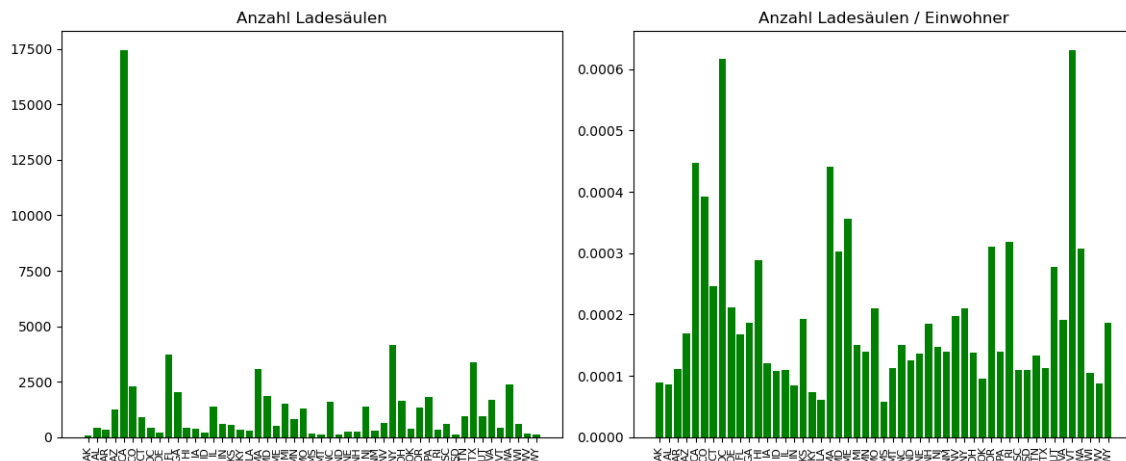
```
# Welche Bundesstaaten haben die höchste bzw. niedrigste Anzahl an Ladesäulen
stations_per_state = stations.groupby('State').size().reset_index(name='Count')
stations_per_state = pd.merge(stations_per_state, usa, left_on='State', right_on='Abbreviation')

fig, axs = plt.subplots(1, 2, figsize=(12, 5))

axs[0].bar(stations_per_state['Abbreviation'], stations_per_state['Count'], color='green')
axs[0].set_title('Anzahl Ladesäulen')
axs[0].set_xticks(axs[0].get_xticks())
axs[0].set_xticklabels(axs[0].get_xticklabels(), rotation=90, fontsize=8)

stations_pop = stations_per_state['Count'] / stations_per_state['Population']
axs[1].bar(stations_per_state['Abbreviation'], stations_pop, color='green')
axs[1].set_title('Anzahl Ladesäulen / Einwohner')
axs[1].set_xticks(axs[1].get_xticks())
axs[1].set_xticklabels(axs[1].get_xticklabels(), rotation=90, fontsize=8)

plt.tight_layout()
plt.show()
```



Zunächst werden die Ladestationen pro Bundesstaat gezählt und mit Bevölkerungsdaten verknüpft. Der erste Subplot zeigt die absolute Anzahl der Ladestationen pro Bundesstaat, während der zweite Subplot die Anzahl der Ladestationen je Einwohner pro Bundesstaat darstellt. Besonders hervorstechend ist der Staat Kalifornien, welcher ein Vielfaches mehr an Ladesäulen hat, als der Staat mit den zweitmeisten Ladesäulen (New York). Vermont, Massachusetts, District of Columbia (DC) und Colorado besitzen viele Ladesäulen pro Einwohner.

5.5 Zeitliche Entwicklung der Anzahl der Ladesäulen + Trend

```
# Wie hat sich die Anzahl der Ladesäulen im Laufe der Zeit entwickelt
# Gibt es einen Trend in der Eröffnung von Ladesäulen über die Jahre?
stations_dev = stations.groupby(stations['Open Date'].dt.date).size().cumsum().reset_index(name='Count')

stations_trend = stations.groupby(stations['Open Date'].dt.year).size().reset_index(name='Count')
# erst ab 2000, davor zu gering
# es gibt eine Station 2024 im Datensatz
stations_trend = stations_trend[stations_trend['Open Date'] >= 2000]
stations_trend = stations_trend[stations_trend['Open Date'] != 2024]

x = stations_trend['Open Date']
y = stations_trend['Count']

# Quadratische Regression (Polynomgrad 2)
coefficients = np.polyfit(x, y, 2)

# Erzeugung einer quadratischen Funktion mit den berechneten Koeffizienten
quadratic_function = np.poly1d(coefficients)

# Vorhersage für Werte in x
predicted_y = quadratic_function(x)

r_2 = r2_score(y, predicted_y)
mse = np.mean((y - predicted_y)**2)


s20 = stations_dev.loc[stations_dev['Open Date'] >= pd.Timestamp(2020, 1, 1)]
s23 = stations_dev.loc[stations_dev['Open Date'] >= pd.Timestamp(2023, 1, 1)]

fig, axs = plt.subplots(1, 2, figsize=(12, 4), gridspec_kw={'width_ratios': [4.5, 5.5]})

axs[0].set_title('Kumulative Anzahl der Ladesäulen über die Zeit')
axs[0].plot(stations_dev['Open Date'], stations_dev['Count'], linestyle='-', label='Linie')
axs[0].scatter([s20.values[0][0], s23.values[0][0]], [s20.values[0][1], s23.values[0][1]], color='red')
axs[0].text(s20.values[0][0], s20.values[0][1], '2020-01', bbox=dict(facecolor='white', alpha=0.3))
axs[0].text(s23.values[0][0], s23.values[0][1], '2023-01', bbox=dict(facecolor='white', alpha=0.3))

axs[1].set_title('Entwicklung der Eröffnung von Ladesäulen pro Jahr')
axs[1].scatter(x, y)
axs[1].plot(x, predicted_y, label='Regression', color='red')
axs[1].text(min(x), max(y), f'R^2: {r2_score(y, predicted_y):.3f}\nMSE: {mse:.1f}\nRMSE: {np.sqrt(mse):.1f}',
            verticalalignment='top', bbox=dict(facecolor='white', alpha=0.3))
axs[1].legend(loc='lower right')

plt.tight_layout()
plt.show()
```



Das linke Diagramm zeigt die kumulative Anzahl der Ladesäulen von 1996 bis heute. Hierfür gruppieren wir den Datensatz aller Ladesäulen anhand des Eröffnungstages, indem für jeden Tag im Datensatz die Anzahl der Zeilen gezählt werden. Diese werden auf die bereits existierenden Ladesäulen dazuaddiert. Dadurch erhalten wir ein Dataframe, welches

für jeden Tag an dem neue Ladesäulen eröffnet wurden, die aktuelle Anzahl aller Ladesäulen der ganzen USA enthält. Hierbei fällt besonders auf, dass sich die Anzahl der Ladesäulen innerhalb von 2 Jahren (Anfang 2020 bis Anfang 2023) von knapp 20.000 auf nahezu 60.000 fast verdreifacht hat.


Im rechten Diagramm wird die Anzahl der Eröffnungen von Ladesäulen in der ganzen USA pro Jahr dargestellt. Da die Werte in den ersten Jahre sehr gering ausfallen, entfernen wir diese aus der Analyse und beginnen mit dem Jahr 2000. Zudem löschen wir das Jahr 2024, da unser Datensatz bereits einen Eintrag für 2024 enthält, dieser aber nicht repräsentativ für das ganze Jahr ist. Durch die Regression ist ein klarer Aufwärtstrend zuerkennen. Daher ist anzunehmen, dass die Anzahl an neueröffneten Ladesäulen pro Jahr in den nächsten Jahren weiter ansteigt.

5.6 Korrelation zw. Anzahl der Ladesäulen und anderen Faktoren

```
# Korrelation zw. der Anzahl Ladesäulen und anderen Faktoren, wie der Bevölkerung, Bevölkerungsdichte?
stations_corr = stations.groupby(stations['State']).size().reset_index(name='Count')
stations_corr = pd.merge(stations_corr, usa, left_on='State', right_on='Abbreviation')
stations_corr['Population density'] = stations_corr['Population'] / stations_corr['Land_area']

# Korrelationsmatrix erstellen
correlation_matrix = stations_corr[['Count', 'Population', 'Population density']].corr()

# Heatmap der Korrelationsmatrix erstellen
plt.figure(figsize=(9, 3))
sns.heatmap(correlation_matrix, annot=True, cmap='coolwarm', fmt='.2f', linewidths=.5)
plt.title('Korrelationsmatrix zw. Anzahl Ladesäulen und Bevölkerung / Bevölkerungsdichte')
plt.xticks(rotation=0)
plt.show()
```



Im Vorliegenden haben wir die Korrelation zwischen Anzahl der Ladesäulen, Bevölkerung und Bevölkerungsdichte in den USA analysiert. Zunächst werden die Ladestationen pro Bundesstaat gezählt und mit Bevölkerungsdaten verknüpft, daraufhin wird die Bevölkerungsdichte berechnet und gespeichert. Eine Korrelationsmatrix zeigt die Beziehung zwischen Ladestationen, Bevölkerung und Dichte. Die Heatmap visualisiert die Korrelationen und ermöglicht eine einfache Interpretation der Verbindungen zwischen Ladesäulen und Bevölkerungsfaktoren. So zeigt die Heatmap, dass die Korrelation zwischen Anzahl der Ladesäulen und Bevölkerungsanzahl besonders hoch ist, die Ladesäulenanzahl jedoch nur eine geringe Korrelation zur Bevölkerungsdichte hat. Allgemein lässt sich sagen, dass eine hohe Bevölkerungszahl mit vielen Ladesäulen einhergeht.

5.7 Korrelation zw. Anzahl der E-Autos und politischer Einstellung

```
# registrations / politischer Mehrheit - stations / politischer Mehrheit
reg_vote = registrations[registrations['Year'] == 2022]
reg_vote = pd.merge(registrations, usa, on='State')
reg_vote = reg_vote.groupby('Vote')['Electric'].sum().reset_index(name='Count')


stations_vote = pd.merge(stations, usa, left_on='State', right_on='Abbreviation')
stations_vote = stations_vote.groupby('Vote').size().reset_index(name='Count')

fig, axs = plt.subplots(1, 2, figsize=(10, 4.5))

axs[0].pie(reg_vote['Count'], autopct='%1.1f%%', startangle=90, colors=['blue', 'lightblue', 'lightcoral',
↵ 'red', 'grey'])
axs[0].set_title('Registrierte E-Autos (2022) nach politischer Mehrheit')
axs[0].set_xticks(axs[0].get_xticks())
axs[0].set_xticklabels(axs[0].get_xticklabels(), rotation=90, fontsize=8)
axs[0].legend(stations_vote['Vote'], loc="upper left")

axs[1].pie(stations_vote['Count'], autopct='%1.1f%%', startangle=90, colors=['blue', 'lightblue',
↵ 'lightcoral', 'red', 'grey'])
axs[1].set_title('Anzahl Ladesäulen nach politischer Mehrheit')
axs[1].set_xticks(axs[1].get_xticks())
axs[1].set_xticklabels(axs[1].get_xticklabels(), rotation=90, fontsize=8)
axs[1].legend(stations_vote['Vote'], loc="upper right")

plt.tight_layout()
plt.show()
```



Nun möchten wir analysieren, wie die politischen Ausrichtung der Bundesstaaten mit Registrierungen von E-Autos zusammenhängt. Dazu nutzen wir die Registrierungsdaten pro Bundesstaat aus 2022 und vereinigen diese mit den politischen Ausrichtungen des jeweiligen Staates aus dem USA-Datensatz. Analog geschieht das ebenfalls mit der Anzahl von Ladesäulen pro Bundesstaat. Daraufhin visualisieren wir mit zwei Kreisdiagrammen ein klares Bild: Die E-Mobilität ist in den 'blue states' bzw. 'light blue states' also in Bundesstaaten, in denen vier bzw. drei der letzten US-Wahlen von den Demokraten gewonnen wurden, weitaus entwickelter und beliebter. Der Grund dafür könnte die konservative Grundstimmung der 'red states' bzw. 'light red states' sein. In jenen Staaten wurde vier bzw. drei von vier Legislaturperioden republikanisch gewählt. In den 'swing states' (zwei von vier Wahlen republikanisch bzw. demokratisch gewählt) gibt es keine große Auffälligkeit.

6 Evaluation

Und was lernen wir nun daraus? Eins lässt sich klar sagen: Unsere Fragen ließen sich größtenteils gut beantworten und die Analyse war sehr aufschlussreich. Unsere Analysen können hilfreich für alle möglichen Unternehmen und Kunden in der Branche der E-Mobilität sein, bei Fragen wie – 'Wo gibt es bereits ein großes Ladenetz, sodass wir unsere Autos leichter absetzen können?' – oder – 'Wäre es bei meinem Umzug nach Massachusetts Zeit für ein E-Auto?' – haben wir die Antwort. Im Detail kamen wir zu den Antworten, dass Kalifornien als Vorreiter der E-Mobilität in den USA sowohl in der Ladesäuleninfrastruktur aber auch insbesondere in der Beliebtheit des E-Auto den meisten Staaten weit voraus ist. Hawaii und Washington sind ebenfalls hoch im Kurs, hingegen hat Maine zwar eher wenige Registrierungen, dennoch eine gute Ladesäuleninfrastruktur. Dabei ist zu unterstreichen, dass all diese Staaten zwei Dinge gemeinsam haben: Sie sind an der Küste und überwiegend unter demokratischer Führung. Allgemein sind Binnenstaaten und Staaten in republikanischer Hand in Sachen E-Mobilität recht unterentwickelt. Wir hatten zunächst angenommen, das läge an dem Fakt, dass republikanische Staaten größtenteils eher ländlicher und nicht dicht besiedelt sind. Jedoch zeigte unsere Korrelationsmatrix das gegenteilige Bild. Für eine Korrelationsmatrix mit der Bevölkerungsdichte wäre es eventuell besser gewesen, die USA kleinteiliger als in Bundesstaaten, beispielsweise in Counties, zu unterteilen. Dadurch verfälschen die riesigen Metropolen weniger die nebenliegenden ländlicheren Flächen der Bundesstaaten, wodurch wir genauere Infos über die Entwicklung der E-Mobilität in ländlicheren Gegenden erhalten hätten. Es stellt sich heraus, dass in Staaten mit vielen Ladesäulen auch viele E-Autos zu finden sind, doch ob nun die gegebene Infrastruktur die Verkäufe ankurbelt oder umgekehrt, bedarf weiterer Forschung.